

# Minimum Jerk

## 一些假设与背景

下列问题都是在单一维度进行的！比如x方向，y方向或者z方向，如果想要综合考虑，只需要把代价函数和约束加起来即可。

对于轨迹优化 (jerk) 问题，一般假设轨迹为五次多项式：

$$x(t) = p_5 t^5 + p_4 t^4 + p_3 t^3 + p_2 t^2 + p_1 t + p_0 \quad (1)$$

这里的次数选择依据于：

如果只有一段轨迹，即只有始末两个节点，并且对jerk进行最小化，那么状态量就是x, v, a, 此时一共有6个约束参数，等价于有6个方程。那么如果想要方程可解，**需要有大等于6个参数**，如果大于6个就是欠定方程组（一般无穷组解），小于6个就是超定方程组（一般无解）。

因此多项式最高次数为5，此时刚好有6个参数（当然大于6个也可以）。

实际中，在始末两点之间可能指定通过多个路径点，但是在这些中间点中除了位置外，其他状态并不做硬约束，而是在优化中得到他们的值。

## 凸优化问题

损失函数最小化jerk或者最小化snap其实都可以，这里以最小化jerk中最简单的形式举例，不考虑其他软约束。待优化函数为：

$$J_j(T) = \int_{T_{j-1}}^{T_j} [x^{(3)}(t)]^2 dt \quad (2)$$

其中j代表第j段路径。

$$\begin{aligned} x^{(3)}(t) &= \sum_{i \geq 3} i(i-1)(i-2)t^{i-3}p_i \\ [x^{(3)}(t)]^2 &= \sum_{i \geq 3, l \geq 3} i(i-1)(i-2)l(l-1)(l-2)t^{i+l-6}p_i p_l \\ J_j(T) &= \int_{T_{j-1}}^{T_j} [x^{(3)}(t)]^2 dt \\ J_j(T) &= \sum_{i \geq 3, l \geq 3} \frac{i(i-1)(i-2)l(l-1)(l-2)}{i+l-5} (T_j^{i+l-5} - T_{j-1}^{i+l-5}) p_i p_l \\ J_j(T) &= \begin{bmatrix} p_3 \\ p_4 \\ p_5 \end{bmatrix}^T * \begin{bmatrix} A_{33} & A_{34} & A_{35} \\ A_{43} & A_{44} & A_{45} \\ A_{53} & A_{54} & A_{55} \end{bmatrix} * \begin{bmatrix} p_3 \\ p_4 \\ p_5 \end{bmatrix} \end{aligned}$$

那么整段路径的损失函数为：

$$J(T) = \begin{bmatrix} \vec{p}_1 \\ \vec{p}_2 \\ \cdot \\ \cdot \\ \vec{p}_M \end{bmatrix}^T * \begin{bmatrix} Q_1 & 0 & \dots & 0 \\ 0 & Q_2 & \dots & 0 \\ \cdot & \cdot & \dots & \cdot \\ 0 & 0 & 0 & Q_M \end{bmatrix} * \begin{bmatrix} \vec{p}_1 \\ \vec{p}_2 \\ \cdot \\ \cdot \\ \vec{p}_M \end{bmatrix}$$

约束条件有两个：节点状态和连续性

$$\begin{aligned}
 f_j^{(k)}(T_j) &= x_j^{(k)} \\
 \Rightarrow \sum_{i \geq k} \frac{i!}{(i-k)!} T_j^{i-k} p_{j,i} &= x_{T,j}^{(k)} \\
 \Rightarrow \begin{bmatrix} \dots & \frac{i!}{(i-k)!} T_j^{i-k} & \dots \end{bmatrix} \begin{bmatrix} \vdots \\ p_{j,i} \\ \vdots \end{bmatrix} &= x_{T,j}^{(k)} \\
 \Rightarrow \begin{bmatrix} \dots & \frac{i!}{(i-k)!} T_{j-1}^{i-k} & \dots \\ \dots & \frac{i!}{(i-k)!} T_j^{i-k} & \dots \end{bmatrix} \begin{bmatrix} \vdots \\ p_{j,i} \\ \vdots \end{bmatrix} &= \begin{bmatrix} x_{0,j}^{(k)} \\ x_{T,j}^{(k)} \end{bmatrix} \\
 \Rightarrow \mathbf{A}_j \mathbf{p}_j &= \mathbf{d}_j
 \end{aligned}$$

$$\begin{aligned}
 \overbrace{f_j^{(k)}(T_j)}^{f_{j+1}^{(k)}(T_j)} &= f_{j+1}^{(k)}(T_j) \\
 \Rightarrow \sum_{i \geq k} \frac{i!}{(i-k)!} T_j^{i-k} p_{j,i} - \sum_{l \geq k} \frac{l!}{(l-k)!} T_j^{l-k} p_{j+1,l} &= 0 \\
 \Rightarrow \begin{bmatrix} \dots & \frac{i!}{(i-k)!} T_j^{i-k} & \dots & -\frac{l!}{(l-k)!} T_j^{l-k} & \dots \end{bmatrix} \begin{bmatrix} \vdots \\ p_{j,i} \\ \vdots \\ p_{j+1,l} \\ \vdots \end{bmatrix} &= 0 \\
 \Rightarrow [\mathbf{A}_j \quad -\mathbf{A}_{j+1}] \begin{bmatrix} \mathbf{p}_j \\ \mathbf{p}_{j+1} \end{bmatrix} &= 0
 \end{aligned}$$

这两个条件可以合并到一个矩阵，因此整个优化问题为：

$$\begin{aligned}
 \min \begin{bmatrix} \vec{p}_1 \\ \vec{p}_2 \\ \cdot \\ \cdot \\ \cdot \\ \vec{p}_M \end{bmatrix}^T & * \begin{bmatrix} Q_1 & 0 & \dots & 0 \\ 0 & Q_2 & \dots & 0 \\ \cdot & \cdot & \dots & \cdot \\ 0 & 0 & 0 & Q_M \end{bmatrix} * \begin{bmatrix} \vec{p}_1 \\ \vec{p}_2 \\ \cdot \\ \cdot \\ \cdot \\ \vec{p}_M \end{bmatrix} \\
 s.t. \quad A_{eq} * \begin{bmatrix} \vec{p}_1 \\ \vec{p}_2 \\ \cdot \\ \cdot \\ \cdot \\ \vec{p}_M \end{bmatrix} &= d_{eq}
 \end{aligned}$$

这是一个标准的凸优化中的QP问题。

由于此时的变量是不具有物理意义的，只是多项式的次数，这样是数值不稳定的，因此将它们转换为具有物理意义的各阶导数。

$$\text{设 } M_j \vec{p}_j = \vec{d}_j$$

$$x(t) = p_5 t^5 + p_4 t^4 + p_3 t^3 + p_2 t^2 + p_1 t + p_0$$

$$x'(t) = 5p_5 t^4 + 4p_4 t^3 + 3p_3 t^2 + 2p_2 t + p_1$$

$$x''(t) = 20p_5 t^3 + 12p_4 t^2 + 6p_3 t + 2p_2$$

由于  $x(0) = p_0, x'(0) = v_0, x''(0) = a_0, x(T) = p_T, x'(T) = v_T, x''(T) = a_T$ , 因此有

$$M = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 \\ T^5 & T^4 & T^3 & T^2 & T & 1 \\ 5T^4 & 4T^3 & 3T^2 & 2T & 1 & 0 \\ 20T^3 & 12T^2 & 6T & 2 & 0 & 0 \end{bmatrix}$$

$$J = \begin{bmatrix} \vec{d}_1 \\ \vec{d}_2 \\ \cdot \\ \cdot \\ \cdot \\ \vec{d}_M \end{bmatrix}^T * \begin{bmatrix} M_1 & 0 & \dots & 0 \\ 0 & M_2 & \dots & 0 \\ \cdot & \cdot & \dots & \cdot \\ 0 & 0 & 0 & M_M \end{bmatrix}^{-T} * \begin{bmatrix} Q_1 & 0 & \dots & 0 \\ 0 & Q_2 & \dots & 0 \\ \cdot & \cdot & \dots & \cdot \\ 0 & 0 & 0 & Q_M \end{bmatrix} * \begin{bmatrix} M_1 & 0 & \dots & 0 \\ 0 & M_2 & \dots & 0 \\ \cdot & \cdot & \dots & \cdot \\ 0 & 0 & 0 & M_M \end{bmatrix}^{-1} * \begin{bmatrix} \vec{d}_1 \\ \vec{d}_2 \\ \cdot \\ \cdot \\ \cdot \\ \vec{d}_M \end{bmatrix}$$

此时就可以作为一个凸优化中标准的QP问题求解了，但高飞还讲了一种closed form的解法，**就是把约束量隐含在代价函数中，进而就可以作为无约束的问题求解，相当于求解二次函数极值点了**

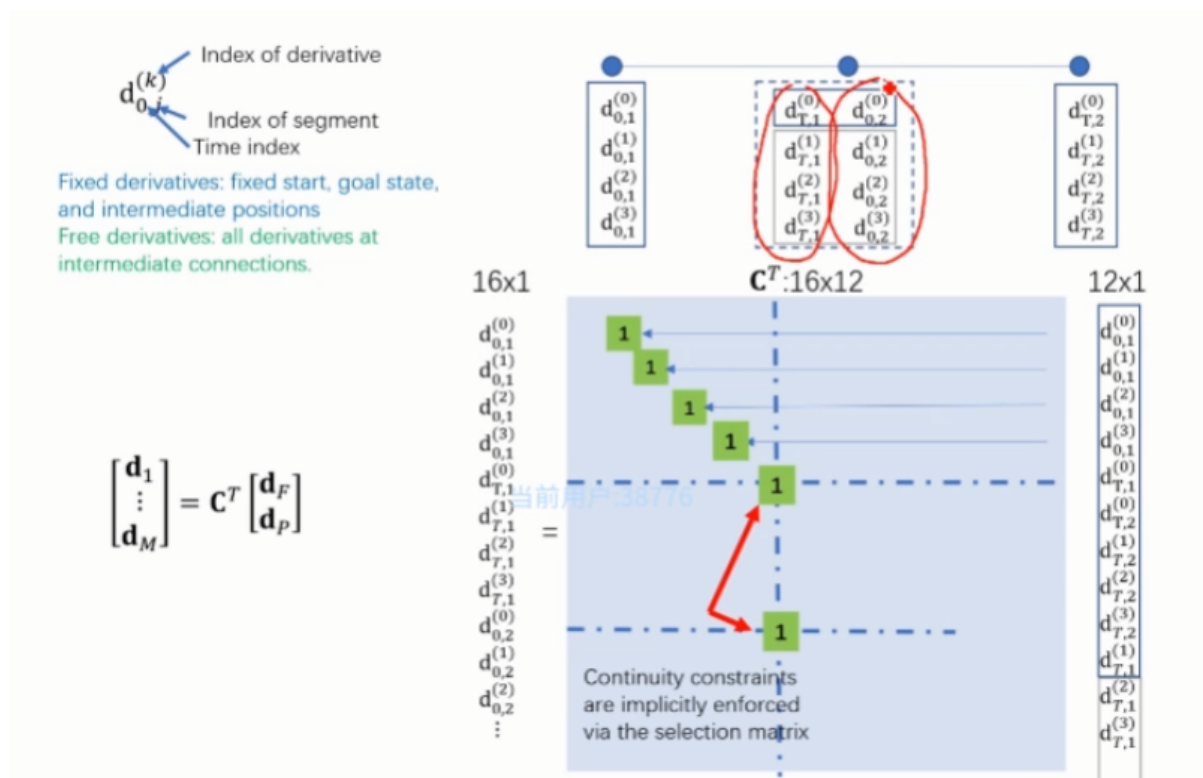
设  $\vec{d}_F$  是约束条件中的约束状态量， $\vec{d}_P$  是在优化过程中确定的自由量，比如中间节点的速度和加速度

$$C^T \begin{bmatrix} \vec{d}_F \\ \vec{d}_P \end{bmatrix} = \begin{bmatrix} \vec{d}_1 \\ \vec{d}_2 \\ \cdot \\ \cdot \\ \cdot \\ \vec{d}_M \end{bmatrix}$$

注意，由于连续性约束，因此等式右边的状态量是有重复的，比如第一段的  $T$  时刻和第二段的  $0$  时刻。

因此经过  $C^T$  转换后，两个向量的维度不一样。

$C^T$  的求法也很简单，把两个向量摆在等式左右两边，对照着把1填在对应的位置就行。



由于 $d_F$ 中的值并不是变量，而是根据约束条件给定的，并且在删除重复状态量的过程中，也是隐含了满足连续性条件，因此在这个方程中其实已经隐含了所有的约束，此时就可以转化为一个无约束问题。

$$J = \begin{bmatrix} \vec{d}_F \\ \vec{d}_P \end{bmatrix}^T \mathbf{C} \mathbf{M}^{-T} \mathbf{Q} \mathbf{M}^{-1} \mathbf{C}^T \begin{bmatrix} \vec{d}_F \\ \vec{d}_P \end{bmatrix} = \begin{bmatrix} \vec{d}_F \\ \vec{d}_P \end{bmatrix}^T \begin{bmatrix} R_{FF} & R_{FP} \\ R_{PF} & R_{PP} \end{bmatrix} \begin{bmatrix} \vec{d}_F \\ \vec{d}_P \end{bmatrix}$$

$$J = d_F^T R_{FF} d_F + d_F^T R_{FP} d_P + d_P^T R_{PF} d_F + d_P^T R_{PP} d_P$$

$$d_P^* = -R_{PP}^{-1} R_{FP}^T d_F$$

## 工程上的细节处理

### 归一化

$$f(t) = \begin{cases} f_1(t) \doteq \sum_{i=0}^N p_{1,i} t^i & T_0 \leq t \leq T_1 \\ f_2(t) \doteq \sum_{i=0}^N p_{2,i} t^i & T_1 \leq t \leq T_2 \\ \vdots & \vdots \\ f_M(t) \doteq \sum_{i=0}^N p_{M,i} t^i & T_{M-1} \leq t \leq T_M \end{cases}$$

如果采用累积时间作为每段时间的记法，那么当时间累积很大时，运算结果会非常大，数值非常不稳定，因此采用相对时间记录。归一化之后并不会影响多项式参数的计算，只是将多项式压缩了一下，形状不变，可以在得到多项式系数后再拉伸回来。

$$f(t) = \begin{cases} \sum_{i=0}^N p_{1,i} \left( \frac{t - T_0}{T_1 - T_0} \right)^i & T_0 \leq t \leq T_1 \\ \sum_{i=0}^N p_{2,i} \left( \frac{t - T_1}{T_2 - T_1} \right)^i & T_1 \leq t \leq T_2 \\ \vdots & \vdots \\ \sum_{i=0}^N p_{M,i} \left( \frac{t - T_{M-1}}{T_M - T_{M-1}} \right)^i & T_{M-1} \leq t \leq T_M \end{cases}$$

同理如果空间体积很大的话，也可以将空间归一化，在一个类似沙盘上求解。

- Problem scale (spatial) normalization
  - If the problem is underlying for large-scale scene.
  - Such as waypoints with  $x = 100.0 \text{ m}$
  - Consider solve a tiny problem (a sandbox), and re-scale the solution back.

## 维度的独立问题

对于无人机来说，由于三个维度是解耦的，因此在优化函数中不存在软约束时，可以三个维度独立求解。但如果加入软约束，需要将三个维度信息一起代入软约束求值，此时就需要将三个维度的损失函数求和。

## Is closed-form solution always better?

作者在论文中说closed-form的求解是更好的，但这涉及矩阵的求逆，因此如果计算资源不够的话，还是使用标准的QP问题求解方式。

## 是否可以用多项式作为所有问题的路径假设？

几乎是，但有一些情况多项式不是最优的。当损失函数是两个状态量加权时，比如：

$$J = \int_0^T \rho_1 \cdot jerk^2(t) + \rho_2 \cdot snap^2(t) dt$$

此时多项式就不是一个最优的假设，但也是逼近最优的，所以理论上用多项式也可以。